

ESPECIFICACIÓN DE LA CAPA DE MEDICIÓN

Métricas confiables para el análisis de brechas
con IA generativa

Versión 2 del diseño — reemplaza la capa de validación actual

Documento	Complementa al Plan de Evolución Técnica
Alcance	Detalle de las Fases 3 y 7 del plan (niveles 7 y 8)
Propósito del sistema	Herramienta de apoyo para investigadores y estudiantes
Métricas actuales	6 mediciones, 4 dimensiones
Métricas propuestas	24 mediciones en 7 niveles
Fecha	09 de agosto de 2026
Estado	DISEÑO PARA ACUERDO — sin cambios de código aún

SECCIÓN 1

El principio que ordena todo el diseño

La capa de medición actual falla por una razón que no es de implementación sino conceptual, y entenderla determina cómo se construye la versión nueva.

Una brecha de investigación no está escrita en el artículo. Por definición es aquello que el artículo no cubre. Por eso medir la similitud entre la brecha y el texto fuente, como hace el sistema hoy, es una contradicción: premia a la brecha que más se parece al artículo, es decir, a la que menos aporta.

Decisión de diseño central: separar afirmación evidencial de afirmación inferencial

Toda brecha bien formulada contiene dos componentes distintos que deben medirse de forma distinta.

Componente evidencial — lo que el artículo sí dice. «*El estudio evalúa el modelo únicamente sobre datos de un hospital y con validación simple.*» Esto **debe** ser verificable contra el texto. Aquí la fidelidad a la fuente es la métrica correcta y una afirmación no respaldada es una alucinación.

Componente inferencial — lo que se concluye. «*Por tanto falta evidencia sobre generalización multicéntrica.*» Esto **no puede** verificarse contra el artículo, porque precisamente afirma lo que el artículo no hace. Se valida contra la cobertura del corpus y, en última instancia, contra juicio experto.

Medir ambos componentes con la misma métrica —que es lo que ocurre hoy— garantiza que ninguno de los dos quede bien medido.

1.1 Los cinco principios

Principio	Qué implica en la práctica
1. Cada métrica mide una sola cosa y se llama como lo que mide	Nada de indicadores compuestos opacos. <code>val_score</code> mezcla hoy similitud y conteo de aciertos en un solo número que no significa nada interpretable. Se elimina en favor de métricas separadas.
2. Ninguna métrica puede ser cuasi-constante	Se exige que cada métrica tenga varianza demostrada sobre datos reales. Se reportan mediana y rango intercuartílico, no solo la media. Una métrica con rango intercuartílico menor a 0.05 se considera inservible y se retira.
3. Los umbrales se calibran, no se inventan	Ningún umbral fijo escrito a mano. Se derivan de percentiles de la distribución observada sobre un corpus de calibración, y se documenta el percentil elegido.
4. Toda métrica automática debe predecir el juicio humano	Si una métrica no correlaciona con la valoración de un experto, es decorativa aunque sea sofisticada. Esta es la meta-métrica de la Sección 5.
5. El sistema debe poder decir que no sabe	Una herramienta de apoyo a la investigación gana confianza admitiendo incertidumbre. Se introduce abstención explícita en lugar de forzar siempre una salida.

SECCIÓN 2

Hallazgo adicional: la recuperación no se está ejecutando

Durante el diseño de esta especificación se detectó un problema que no figuraba en el plan anterior y que afecta a la base de todo el sistema.

La «R» de RAG no está operando en la ruta de análisis

El análisis de cada artículo obtiene su contexto llamando a `get_top_chunks()` en `routers/runs.py:200`. Esa función, definida en `services/embedding_service.py:129`, ejecuta `ORDER BY chunk_order ASC LIMIT 8`: devuelve los **ocho primeros fragmentos del documento**, no los ocho más relevantes.

El nombre de la función sugiere relevancia (*top*) pero el criterio es posicional. La función de recuperación real, `embed_query()`, existe y funciona, pero solo la utiliza el endpoint de búsqueda manual y el cálculo de similitud.

Consecuencia: el contexto que recibe el modelo son siempre los primeros 9.600 caracteres aproximadamente, es decir, resumen e introducción. Metodología, resultados, discusión y limitaciones —justamente donde está la información que revela una brecha— nunca entran al prompt. El sistema descrito como RAG está operando, en la práctica, como un truncado fijo.

Este hallazgo se numera **M-10** y su severidad es **crítica**. Explica parcialmente la genericidad de las brechas: el modelo solo ve la introducción de cada artículo, que es la sección más homogénea entre artículos distintos. También agrava M-09: si el truncado por la palabra *References* ya recorta el documento, y encima solo se usan los primeros fragmentos, la proporción del artículo realmente analizada puede ser muy pequeña.

La corrección forma parte del Nivel 1 de esta especificación e implica dos cambios: recuperar por relevancia usando una consulta construida a partir del contexto del proyecto, y garantizar cobertura seccional mínima incluyendo deliberadamente fragmentos de metodología, resultados y limitaciones.

2.1 Estrategia de recuperación propuesta

- **Consulta híbrida.** Construir el vector de consulta a partir del tema, el objetivo y el sector del proyecto, no a partir de una cadena vacía o del orden del documento.
- **Recuperación por relevancia real** con `embed_query()`, que ya existe.
- **Cuota seccional obligatoria.** Reservar posiciones para fragmentos etiquetados como metodología, resultados, discusión y limitaciones, de modo que ninguna sección quede fuera por efecto del ranking.
- **Diversificación.** Penalizar fragmentos redundantes entre sí para no llenar el contexto con ocho variantes del mismo párrafo.
- **Registro de trazabilidad.** Guardar qué fragmentos se usaron en cada análisis, poblando la tabla `rag_log` que ya está en el esquema y nunca se usó.

SECCIÓN 3

Arquitectura de medición en siete niveles

La capa nueva se organiza en siete niveles ordenados por dependencia. Un nivel solo tiene sentido si el anterior está sano: no sirve medir la calidad de una brecha si el texto del que proviene estaba truncado. Este encadenamiento es lo que hoy no existe.

Nivel	Qué evalúa	Métricas	Coste
N0	Calidad de ingesta y extracción	4	Nulo
N1	Calidad de la recuperación	3	Bajo
N2	Fidelidad a la fuente (anti-alucinación)	3	Alto
N3	Especificidad y discriminación	4	Bajo
N4	Calidad del resumen	4	Medio
N5	Tipificación y síntesis	4	Medio
N6	Anclaje humano y calibración	4	Humano

N0 Calidad de ingesta y extracción

Nivel completamente ausente hoy. La única comprobación existente es que el texto extraído supere 300 caracteres. Todo lo demás se calcula sobre un texto cuya integridad nadie verifica.

ID	Métrica	Qué mide y cómo se calcula	Estado
N0.1	Cobertura de extracción	Caracteres extraídos divididos entre el estimado por número de páginas. Detecta PDFs escaneados, protegidos o mal parseados. Por debajo de 0.25 el artículo se rechaza con motivo explícito en lugar de analizarse a medias.	NUEVA
N0.2	Ratio de truncamiento	Caracteres tras la limpieza divididos entre los caracteres antes de limpiar. Expone directamente el efecto de M-09: si el corte por <i>References</i> elimina el 70% del documento, esta métrica lo revela de inmediato.	NUEVA
N0.3	Detección estructural	Cuántas de las secciones canónicas (resumen, introducción, método, resultados, discusión, referencias) se identificaron. Habilita la cuota seccional de la recuperación y la extracción del abstract real.	NUEVA
N0.4	Legibilidad del texto	Proporción de tokens reconocibles como palabras de español o inglés. Por debajo de 0.70 indica extracción defectuosa y dispara el OCR de respaldo, que hoy existe pero nunca se ejecuta.	NUEVA

N1 Calidad de la recuperación

Diagnostica el componente RAG por separado del modelo generativo. Sin esta separación es imposible saber si una brecha pobre se debe a que el modelo razonó mal o a que nunca recibió la información.

ID	Métrica	Qué mide y cómo se calcula	Estado
N1.1	Precisión del contexto	De los fragmentos recuperados, qué proporción es realmente pertinente para el objetivo del proyecto. Se evalúa con juez automático calibrado. Responde: ¿le estamos dando basura al modelo?	NUEVA
N1.2	Cobertura seccional	Qué secciones del artículo están representadas entre los fragmentos entregados. Con la implementación actual esta métrica daría prácticamente cero para método, resultados y discusión, confirmando M-10 de forma cuantitativa.	NUEVA
N1.3	Diversidad del contexto	Uno menos la similitud media por pares entre los fragmentos recuperados. Valores bajos indican que el contexto repite la misma idea y desperdicia la ventana del modelo.	NUEVA

N2 Fidelidad a la fuente (anti-alucinación)

Aquí se aplica la separación evidencial e inferencial de la Sección 1. Es el nivel que sustituye a la similitud coseno como indicador de confianza y el que más aporta a que un investigador pueda fiarse del resultado.

ID	Métrica	Qué mide y cómo se calcula	Estado
N2.1	Fidelidad evidencial	Métrica central del sistema. Se descompone la brecha en afirmaciones atómicas, se clasifica cada una como evidencial o inferencial, y para las evidenciales se verifica implicación textual contra los fragmentos recuperados. El valor es la proporción de afirmaciones evidenciales respaldadas. Una afirmación evidencial no respaldada es, por definición, una alucinación.	NUEVA
N2.2	Trazabilidad	Proporción de afirmaciones que pueden vincularse a un fragmento concreto y citable. Alimenta la interfaz: el investigador debe poder pulsar sobre una afirmación y ver el párrafo del PDF que la sustenta. Sin esto la herramienta no es auditable.	NUEVA
N2.3	Anclaje léxico-semántico	Es la similitud coseno actual, conservada pero degradada a filtro previo barato y renombrada. Deja de ser una puntuación de calidad y deja de llamarse <i>Identificación de brechas</i> . Solo sirve para descartar salidas manifiestamente desconectadas antes de gastar en verificaciones costosas.	CORREGIDA

N3 Especificidad y discriminación

Este nivel ataca el modo de falla real de los sistemas de detección de brechas con modelos de lenguaje: producir texto correcto, verificable y completamente genérico. Hoy no se mide en absoluto.

ID	Métrica	Qué mide y cómo se calcula	Estado
N3.1	Discriminabilidad inter-artículo	La métrica nueva más diagnóstica. Uno menos la similitud media por pares entre las brechas de artículos <i>distintos</i> del mismo proyecto. Si el sistema emite la misma brecha genérica para los diez artículos, este valor se desploma y lo delata. Sustituye al Jaccard intra-artículo, que nunca detectó nada.	NUEVA
N3.2	Densidad de anclajes concretos	Entidades nombradas, cifras, nombres de método, población, conjunto de datos o métrica por cada cien palabras. Distingue « <i>faltan más estudios en contextos diversos</i> » de « <i>no hay validación externa en cohortes latinoamericanas ni reporte de calibración</i> ».	NUEVA
N3.3	Contenido informativo	Suma de IDF de los términos de contenido, calibrada sobre un corpus académico de referencia. Es lo que la entropía de Shannon pretendía capturar y nunca capturó, ahora medido sobre unidades con significado en lugar de sobre caracteres.	NUEVA
N3.4	Redundancia intra-proyecto	Detección de brechas duplicadas por similitud de embeddings con umbral calibrado, y con alcance sobre todo el proyecto, no solo sobre el mismo artículo.	CORREGIDA

N4 Calidad del resumen

Se conserva ROUGE porque es el estándar comparable en la literatura, pero corrigiendo la referencia y acompañándolo de medidas semánticas que capturen lo que el solape de palabras no ve.

ID	Métrica	Qué mide y cómo se calcula	Estado
N4.1	ROUGE-1, ROUGE-2 y ROUGE-L	Calculados contra el abstract real extraído por N0.3, no contra las primeras 180 palabras del PDF. Se reportan las tres variantes y sus tres componentes. Es la corrección de M-02 y la que más cambiará las cifras publicadas.	CORREGIDA
N4.2	Similitud semántica del resumen	Comparación por embeddings entre resumen generado y abstract. Capta la paráfrasis correcta que ROUGE penaliza por no compartir vocabulario literal. ROUGE y esta métrica juntas dan una lectura mucho más honesta que cualquiera por separado.	NUEVA
N4.3	Fidelidad del resumen	El mecanismo de N2.1 aplicado al resumen: proporción de afirmaciones del resumen respaldadas por el texto del artículo. Un resumen puede tener buen ROUGE y aun así introducir datos inventados.	NUEVA
N4.4	Densidad léxica	Se conserva con lista de palabras vacías completa y separada por idioma, y se reclasifica como estadística descriptiva , no como indicador de calidad. Una densidad alta no significa un resumen mejor.	CORREGIDA

N5 Tipificación y síntesis

La clasificación del tipo de brecha y la generación del estado del arte son dos salidas del sistema que hoy no tienen ninguna métrica asociada.

ID	Métrica	Qué mide y cómo se calcula	Estado
N5.1	Exactitud de tipificación	Exactitud y F1 macro de la clasificación en las cinco categorías frente a etiquetas expertas, con matriz de confusión. El F1 macro es obligatorio por el desbalance esperable entre categorías.	NUEVA
N5.2	Efecto reclasificador del	La función <code>_rebalance_tipo()</code> sobrescribe hoy la decisión del modelo mediante coincidencia de palabras clave. Nadie ha comprobado si ayuda o perjudica. Se mide con comparación A/B sobre el conjunto anotado y se conserva solo si mejora.	NUEVA
N5.3	Cobertura de la síntesis	Qué proporción de las brechas de entrada quedan efectivamente representadas en el estado del arte generado. Detecta si la síntesis está ignorando artículos.	NUEVA
N5.4	Integridad de la síntesis	Afirmaciones del estado del arte no rastreables a ninguna brecha de entrada, y detección de referencias bibliográficas fabricadas. El prompt prohíbe inventar citas; hoy nadie verifica que se cumpla.	NUEVA

N6 Anclaje humano y calibración

Los seis niveles anteriores son automáticos. Sin este nivel ninguno de ellos puede afirmar que mide calidad: solo miden consistencia. Este es el nivel que convierte el sistema en confiable.

ID	Métrica	Qué mide y cómo se calcula	Estado
N6.1	Precisión, exhaustividad y F1	Frente al consenso de anotadores expertos. Precisión: de las brechas propuestas, cuántas validó un experto. Exhaustividad: de las brechas que identificó el experto, cuántas encontró el sistema.	NUEVA
N6.2	Acuerdo entre anotadores	Kappa de Cohen o de Fleiss. Si los propios expertos no se ponen de acuerdo sobre qué es una brecha válida, ninguna cifra del sistema es interpretable. Objetivo mínimo 0.60.	NUEVA
N6.3	Correlación métrica-juicio	La meta-métrica. Correlación de Spearman entre cada métrica automática y la valoración experta. Determina cuáles se conservan. Se detalla en la Sección 5.	NUEVA
N6.4	Utilidad percibida	Valoración por investigadores reales sobre si la brecha resultó útil para su trabajo, y tiempo ahorrado frente a revisión manual. Es la única métrica que mide el objetivo declarado del producto.	NUEVA

3.1 Métricas retiradas

Métrica actual	Motivo del retiro	Reemplazo
Entropía de Shannon (bits y normalizada)	Cuasi-constante por construcción. No mide coherencia ni ninguna otra propiedad útil del texto. Viola el principio 2.	N3.3 (contenido informativo) y N4.2
val_score	Indicador compuesto opaco que mezcla similitud media y un conteo de aciertos con umbral arbitrario. No es interpretable ni auditable. Viola el principio 1.	N2.1, N2.2 y N3.1 por separado
Jaccard para duplicados	Umbral inalcanzable y alcance restringido al mismo artículo, donde el problema no ocurre.	N3.4 con embeddings y alcance de proyecto
Dimensión «Identificación de brechas»	Era la similitud coseno renombrada. El nombre afirmaba medir algo que la métrica no medía.	N6.1 (precisión y exhaustividad reales)

SECCIÓN 4

Controles negativos: la validación más barata y convincente

Antes de cualquier campaña de anotación —que es cara y lenta— existe una batería de pruebas que no requiere anotadores, se automatiza por completo y detecta si el sistema realmente está leyendo los artículos. Es lo primero que preguntaría un revisor exigente y hoy no hay respuesta.

El razonamiento es simple: si se degrada deliberadamente la entrada y las métricas no bajan, entonces las métricas no estaban midiendo comprensión.

Control	Procedimiento	Resultado esperado si el sistema funciona
C1 Permutación de contexto	Analizar el artículo A usando el contexto de proyecto de otro tema completamente distinto.	La brecha debe cambiar sustancialmente. Si apenas cambia, el sistema ignora el contexto del investigador y la personalización es una ilusión.
C2 Texto barajado	Barajar el orden de los párrafos del artículo antes de procesarlo.	Las métricas de fidelidad y especificidad deben caer. Si no caen, no dependen de la estructura del razonamiento del artículo.
C3 Artículo ajeno	Introducir en el proyecto un artículo de un dominio sin relación con el tema declarado.	El sistema debe marcar baja confianza y abstenerse. Si emite una brecha con confianza alta, la abstención no funciona.
C4 Duplicado exacto	Subir el mismo artículo dos veces con nombres de archivo distintos.	Las dos brechas deben ser casi idénticas. Una divergencia grande indica inestabilidad del sistema, no riqueza analítica.
C5 Estabilidad entre ejecuciones	Procesar el mismo artículo cinco veces y medir la varianza de cada métrica.	Con temperatura 0.1 la varianza debe ser baja. Se reporta como intervalo, no se oculta. Es información que el investigador necesita.
C6 Artículo sin brechas evidentes	Procesar una revisión sistemática reciente y exhaustiva del propio tema.	Debe producir brechas más estrechas o abstenerse. Si genera brechas amplias con la misma seguridad, está rellenando una plantilla.

Por qué empezar por aquí

Estos seis controles se implementan en pocos días, no requieren anotadores y producen evidencia objetiva sobre si el sistema funciona. Si C1 o C2 fallan, ninguna sofisticación posterior de las métricas tiene sentido: significaría que el modelo está generando texto plausible sin leer realmente el artículo, y eso hay que arreglarlo antes que nada.

Además son reproducibles por terceros, lo que los convierte en la evidencia más sólida que puede acompañar una publicación o una demostración comercial.

SECCIÓN 5

La meta-métrica: ¿predicen las métricas el juicio humano?

Es posible construir las veinticuatro métricas anteriores con todo rigor técnico y que la capa siga sin servir. El criterio que decide si sirve es uno solo:

Criterio de aceptación de la capa de medición

Una métrica automática se conserva únicamente si **correlaciona con la valoración de un experto humano** sobre las mismas brechas.

Se calcula la correlación de Spearman entre cada métrica y la puntuación experta sobre el conjunto de referencia. Interpretación de la decisión:

rho igual o mayor a 0.65 — la métrica se conserva como indicador de confianza y puede mostrarse al usuario.

rho entre 0.40 y 0.65 — se conserva solo como señal secundaria dentro de un modelo combinado, nunca en solitario.

rho menor a 0.40 — se retira o se reclasifica como estadística descriptiva sin valor de calidad.

Aplicado retroactivamente, este criterio habría eliminado la entropía y `val_score` antes de que llegaran a publicarse.

5.1 Puntuación de confianza y abstención

Las métricas que superen el umbral se combinan en una **puntuación de confianza calibrada** mediante regresión sobre el juicio experto. Calibrada significa que si el sistema declara 0.80 de confianza, aproximadamente el 80% de esas brechas deben resultar válidas para un experto. Es una propiedad verificable, no una etiqueta.

Los tres estados actuales —aceptada, rechazada, pendiente— se sustituyen por cuatro que reflejan lo que el sistema realmente sabe:

Estado	Confianza	Comportamiento de la herramienta
Verificada	Alta	Se muestra con los fragmentos de respaldo enlazados y disponibles para inspección.
Plausible	Media	Se muestra con advertencia explícita y se señalan las afirmaciones no verificadas.
Requiere revisión	Baja	Se muestra separada del resultado principal, marcada como pendiente de criterio humano.
Abstención	Insuficiente	El sistema declara que no puede analizar el artículo con garantías y explica por qué (extracción deficiente, artículo fuera de dominio, contexto insuficiente). No inventa una salida.

La abstención es lo que distingue una herramienta profesional de una demostración. Un investigador que descubre por su cuenta que el sistema le dio una brecha inventada deja de usarlo para siempre; uno al que el sistema le avisa de que no está seguro, sigue confiando en él.

5.2 Reporte de distribuciones

Todo el reporte actual se construye con promedios (`func.avg` en cada consulta), lo que oculta exactamente el problema que tiene el sistema. Se pasa a reportar, para cada métrica, mediana, rango intercuartílico, mínimo, máximo e histograma.

Una media de 0.86 con rango intercuartílico [0.85 – 0.87] indica una métrica muerta. La misma media con rango [0.55 – 0.95] indica una métrica que discrimina. Hoy ambos casos se presentan de forma idéntica, y esa es precisamente la razón por la que el problema pasó desapercibido hasta ahora.

SECCIÓN 6

Coste de medición y estrategia de muestreo

Varias métricas nuevas —N1.1, N2.1, N2.2, N4.3, N5.3 y N5.4— requieren llamadas adicionales a un modelo de lenguaje para descomponer afirmaciones y verificar implicación. Aplicadas a todo, la evaluación podría costar tanto como la generación. Es un problema real de producto y debe resolverse en el diseño, no descubrirse en la factura.

Franja	Qué se ejecuta	Cuándo	Coste
Continua	Todo N0, N1.2, N1.3, N2.3, N3.1 a N3.4, N4.1, N4.2, N4.4	En cada artículo, siempre	Cero adicional. Son cálculos locales sobre embeddings ya generados.
Selectiva	N2.1, N2.2, N4.3 (verificación por juez)	En cada artículo, pero solo sobre las afirmaciones evidenciales, agrupadas en una sola llamada	Aproximadamente una llamada extra por artículo.
Por lote	N5.3 y N5.4 (integridad de la síntesis)	Una vez por ejecución completa, no por artículo	Una llamada por proyecto.
Por campaña	Todo N6 y los controles negativos	En cada versión del sistema o del prompt, sobre el conjunto de referencia	Coste concentrado y planificable.

Regla de diseño

El coste de medición no debe superar el 30% del coste de generación en la operación normal. Las verificaciones caras se agrupan en una sola llamada por artículo con salida estructurada, y las campañas completas se ejecutan por versión del sistema, no por uso del cliente.

Esto además hace que la contabilidad de tokens (S-04 del plan anterior) sea aún más necesaria: sin ella no se puede ni verificar el cumplimiento de esta regla.

6.1 Impacto en el calendario

Esta especificación amplía el alcance de la Fase 3 del plan anterior. La estimación revisada:

Bloque	Contenido	Estimación
3a	Corrección de la recuperación (M-10) y nivel N0 completo. Es prerequisite de todo lo demás.	2 semanas
3b	Controles negativos C1 a C6 automatizados e integrados en la batería de pruebas.	1 semana
3c	Niveles N1, N3 y N4: métricas locales sin coste adicional de modelo.	2 semanas
3d	Nivel N2: descomposición en afirmaciones y verificación de implicación. Es el bloque técnicamente más exigente.	3 semanas
3e	Nivel N5 y reporte de distribuciones en el panel.	2 semanas
3f	Campaña de anotación, N6, calibración de umbrales y de la confianza.	4 a 6 semanas

Total de la Fase 3 revisada: **14 a 16 semanas** frente a las 6 a 8 estimadas antes. El plan completo hasta el nivel 10 pasa de 5–6 meses a **7–8 meses** de trabajo enfocado. El aumento corresponde íntegramente a construir una capa de medición que sea real, que es exactamente el objetivo planteado.

SECCIÓN 7

Orden de ejecución y decisiones pendientes

7.1 Secuencia recomendada

El orden no es negociable en sus primeros pasos: cada bloque depende de que el anterior haya dejado datos confiables.

#	Paso	Por qué va en esta posición
1	Consulta de verificación sobre la base actual	Un minuto de trabajo. Confirma empíricamente el sesgo de aceptación antes de invertir nada más y fija la línea base con la que se compararán todos los resultados posteriores.
2	Corregir M-10 y M-09, e implementar N0	Mientras el modelo solo vea la introducción de cada artículo, cualquier métrica que se construya estará midiendo el análisis de un texto incompleto.
3	Controles negativos C1 a C6	Verifican que el sistema realmente lee los artículos. Si fallan, el problema no está en las métricas sino en el pipeline, y hay que resolverlo antes de seguir.
4	Métricas locales: N1, N3, N4	Sin coste adicional de modelo. Producen enseguida las distribuciones que permiten calibrar umbrales con datos reales en lugar de valores supuestos.
5	Fidelidad evidencial: N2	El bloque de mayor valor y mayor dificultad. Se aborda cuando ya existe una batería de pruebas que detecte regresiones.
6	Síntesis y reporte: N5	Depende de que las métricas por artículo sean confiables.
7	Campaña humana y calibración: N6	Al final, porque anota sobre las salidas del sistema ya corregido. Anotar sobre la versión actual sería desperdiciar el trabajo de los expertos.

7.2 Decisiones que requieren acuerdo

#	Decisión	Opciones y consecuencia
A	Mecanismo de verificación de implicación para N2.1	Un modelo NLI local (más barato, sin coste por uso, requiere infraestructura) frente a un juez basado en modelo de lenguaje (más preciso en textos académicos, con coste por llamada). Recomendación: juez con salida estructurada y agrupación por artículo.
B	Umbral de abstención	Cuán conservador debe ser el sistema. Abstenerse mucho reduce la utilidad percibida; abstenerse poco erosiona la confianza. Recomendación: empezar conservador y relajar con evidencia de la campaña N6.
C	Alcance de la corrección seccional	Detección de secciones por heurísticas de encabezado (rápida, frágil con formatos poco convencionales) frente a un parser estructural especializado (más robusto, más dependencias). Afecta a N0.3 y a toda la cuota seccional.
D	Qué se muestra al usuario final	Las 24 métricas son para desarrollo y validación. El investigador probablemente solo necesita la confianza calibrada, los fragmentos de respaldo y una advertencia clara. Decidir el nivel de exposición evita convertir la interfaz en un tablero ilegible.

Cierre

Esta especificación sustituye seis mediciones por veinticuatro, pero el cambio importante no es la cantidad. Es que cada métrica nueva tiene una definición de lo que mide, un método de cálculo auditable, un umbral derivado de datos y un criterio explícito bajo el cual sería retirada. La capa actual no cumple ninguna de esas cuatro condiciones.

El objetivo declarado del sistema es servir de apoyo a un investigador en decisiones sobre su propia línea de trabajo. Ese objetivo impone un estándar concreto: **el investigador debe poder comprobar por qué el sistema afirma lo que afirma, y el sistema debe avisarle cuando no está seguro**. Las métricas de fidelidad y trazabilidad del nivel N2, junto con la abstención de la Sección 5, son lo que hace eso posible. Todo lo demás

de este documento existe para sostenerlas.