

PLAN DE EVOLUCIÓN TÉCNICA

Sistema de Matriz de Investigación Científica
aplicando IA Generativa

Del prototipo académico (Nivel 3) al producto desplegable (Nivel 10)

Proyecto	capstone-matriz
Base metodológica	Design Science Research Methodology (DSRM)
Stack	Python / FastAPI / React / MySQL / Gemini
Nivel de madurez actual	3 / 10
Nivel objetivo	10 / 10 — despliegue con plan de pago
Esfuerzo estimado	5 a 6 meses de trabajo enfocado
Fecha	08 de agosto de 2026
Estado	BORRADOR PARA ACUERDO — sin cambios de código aún

SECCIÓN 1

Resumen ejecutivo

Este documento consolida el análisis del código fuente del sistema **capstone-matriz** y del artículo científico que lo describe, con tres propósitos: dejar por escrito cuál es el objetivo real del proyecto, inventariar de forma verificable sus deficiencias actuales, y trazar el camino concreto hasta un producto que pueda ofrecerse bajo un plan de pago a investigadores y a instituciones académicas.

El diagnóstico central es el siguiente. **La arquitectura del sistema es correcta.** La cadena PDF, extracción de texto, fragmentación, embeddings, recuperación aumentada, generación con modelo de lenguaje, capa de validación, síntesis versionada y exportables es exactamente la que corresponde a este problema, y esa es la parte difícil de acertar. **La capa de métricas, en cambio, no mide lo que el proyecto afirma que mide.** Y esa capa es, paradójicamente, el diferenciador que se pretende comercializar.

Hallazgo principal

Las métricas reportadas en el artículo no son incorrectas por error de cálculo: están bien calculadas. El problema es que tres de las cuatro dimensiones están dominadas por valores matemáticamente cuasi-constantes, y las reglas de rechazo automático tienen umbrales que en la práctica nunca se alcanzan. El resultado es un sistema que **parece** validarse a sí mismo, produce cifras estables y creíbles, y no discrimina entre una salida buena y una mala.

1.1 Evidencia: predicción desde el código frente a lo publicado

Antes de leer el artículo se derivaron, únicamente a partir del código, los valores que el sistema debería producir. La coincidencia con lo publicado confirma el diagnóstico.

Indicador	Valor predicho leyendo el código	Valor publicado en el artículo	Lectura
Entropía normalizada	Constante 0.50 a 0.54, independiente del contenido	0.518 / 0.521 / promedio 0.52	Coincide
Dimensión Síntesis y claridad	Aproximadamente 48%	48%	Coincide
Dimensión Calidad global	Entre 60% y 65%	65%	Coincide
val_score promedio	Inflado hacia la aceptación, por encima de 0.60	0.86	Coincide
ROUGE-1 recall	Muy bajo por referencia inválida	0.028 a 0.05	Coincide

El artículo interpreta la constancia de la entropía como prueba de *desempeño estable en todas las ejecuciones*. La interpretación correcta es distinta: la entropía de Shannon a nivel de carácter de cualquier texto en español de longitud razonable ronda los 4.2 bits, y el código la normaliza dividiendo entre 8. El valor 0.52 está forzado por la aritmética, no por la calidad del sistema. Dos proyectos distintos darán siempre prácticamente el mismo número, incluso si uno produce brechas excelentes y el otro produce texto sin sentido.

1.2 Resumen del esfuerzo

Fase	Transición	Foco	Duración estimada
Fase 0	—	Acuerdo, alcance y diseño. Sin código.	1 a 2 semanas
Fase 1	3 a 5	Saneamiento técnico y deuda acumulada	2 a 3 semanas
Fase 2	5 a 6	Plataforma: identidad, aislamiento, asincronía	3 a 4 semanas
Fase 3	6 a 8	Corrección y validación metodológica	6 a 8 semanas

Fase	Transición	Foco	Duración estimada
Fase 4	8 a 10	Producto: cuotas, facturación, legal, soporte	6 a 8 semanas

La Fase 3 es la más larga y la más valiosa. Es la única que no puede acelerarse con más horas de programación, porque depende de anotación humana experta. También es la que convierte el trabajo en algo defendible ante un revisor y vendible ante un investigador.

SECCIÓN 2

Objetivo del proyecto

2.1 Objetivo declarado en la investigación

Según el artículo, el proyecto responde a una limitación concreta de la revisión tradicional de literatura: es un proceso lento, incompleto y poco eficiente para identificar brechas académicas. El objetivo formulado bajo DSRM se descompone en dos:

- **Automatizar el análisis de información científica** mediante modelos de IA generativa, procesando, organizando y sintetizando volúmenes de artículos académicos.
- **Construir una matriz analítica** que permita identificar y clasificar brechas académicas de forma estructurada y trazable.

2.2 Objetivo operativo del sistema construido

Traducido a lo que el software efectivamente hace hoy: el usuario define un **Proyecto** (tema principal, objetivo de investigación, metodología, sector y número de artículos), sube esa cantidad de PDFs, y el sistema ejecuta una cadena completa que termina en una matriz de brechas y un estado del arte, ambos exportables.

Etapa	Qué ocurre	Componente
1. Ingesta	Carga de PDF, deduplicación por SHA-256, extracción automática de título y DOI	routers/archivos.py
2. Indexación	Fragmentación en bloques de 1200 caracteres con 200 de solape y generación de embeddings	services/embedding_service.py
3. Análisis	Recuperación de fragmentos y generación de brecha, oportunidad, tipo y resumen	services/gemini_service.py
4. Validación	Cálculo de métricas y decisión automática de aceptada, rechazada o pendiente	services/metrics.py
5. Síntesis	Redacción del estado del arte versionado a partir de las brechas del lote	routers/estado_arte.py
6. Entrega	Matriz en PDF y JSON, brechas en CSV, estado del arte en Markdown, panel de indicadores	routers/export.py

2.3 Objetivo de producto (destino de este plan)

Una herramienta de apoyo a la revisión de literatura que un investigador o un grupo de investigación pueda contratar con confianza. Eso exige tres propiedades que hoy no existen:

- **Confiabilidad demostrada.** Que las cifras de calidad estén respaldadas por comparación contra juicio experto, no por auto-consistencia interna.
- **Aislamiento y seguridad.** Que el trabajo de cada usuario sea privado, y que el consumo sea medible y limitable por cuenta.
- **Operación sostenible.** Que el sistema procese cargas reales sin bloquearse, se pueda desplegar de forma reproducible y tenga una posición clara sobre el material con derechos de autor que sus usuarios suben.

Delimitación explícita de alcance

Este plan **no** contempla entrenar ni ajustar un modelo propio. El sistema es y seguirá siendo un orquestador de modelos de terceros mediante prompting estructurado y recuperación aumentada. Esa decisión es correcta para el problema, pero obliga a que la evaluación se haga sobre las salidas del sistema y no sobre los pesos de un modelo. La Sección 6 desarrolla ese punto.

SECCIÓN 3

Deficiencias actuales y su causa

Se documentan 29 deficiencias agrupadas en cinco bloques. Cada una indica su ubicación exacta en el código, la razón por la que constituye un problema y su severidad. La severidad **Crítica** significa que bloquea el objetivo de producto; **Alta** que compromete la validez o la operación; **Media** que degrada calidad sin bloquear.

3.1 Bloque M: deficiencias metodológicas (las métricas)

Este es el bloque determinante. No compromete el funcionamiento del software, compromete la veracidad de todo lo que el software afirma sobre sí mismo.

ID	Deficiencia y ubicación	Por qué es un problema	Sev.
M-01	La entropía no mide coherencia. Se calcula sobre caracteres. services/metrics.py:484	Cualquier texto en español da unos 4.2 bits; dividido entre 8 queda fijo en 0.50–0.54. La regla de rechazo por <code>entropia_norm > 0.70</code> (línea 174) es inalcanzable: nunca se ha ejecutado. Además el término <code>1 - ent_norm</code> inyecta un 48% constante en la dimensión Síntesis y claridad. La entropía de caracteres detecta texto corrupto, no incoherencia semántica.	Crítica
M-02	Referencia de ROUGE-1 inválida. routers/runs.py:230	Se usa como referencia las primeras 180 palabras del PDF crudo, que son portada, autores, afiliaciones y encabezado de revista. Se está midiendo el solape entre el resumen generado y la carátula del artículo. Esto explica el 0.028–0.05 publicado; el artículo lo atribuye a la tokenización de Gemini, lo cual es un diagnóstico incorrecto. Contra un abstract real el valor esperable es 0.30–0.50.	Crítica
M-03	La similitud coseno mide anclaje, no calidad de brecha. services/metrics.py:99	Una brecha es, por definición, lo que el artículo NO cubre. Que la brecha se parezca al texto fuente es un buen indicador de que el modelo no alucinó, pero el PDF la etiqueta <i>Identificación de brechas</i> . El incentivo resulta perverso: la máxima puntuación la obtiene una brecha que simplemente parafrasea la sección <i>Future Work</i> del propio artículo.	Alta
M-04	Umbral por debajo del piso de ruido. services/metrics.py:172	Se rechaza si la similitud es menor a 0.25, pero el modelo de embeddings empleado produce valores de 0.4 a 0.6 incluso entre textos sin relación alguna. Sumado a M-01, ninguna de las dos reglas de rechazo llega a activarse y <code>val_score</code> se desplaza hacia la aceptación automática (0.86 publicado). La validación automática funciona hoy como un sello de goma.	Crítica
M-05	Detección de duplicados inoperante. services/metrics.py:134 y :141	Jaccard sobre bolsa de palabras con umbral 0.80 prácticamente nunca se alcanza entre dos paráfrasis. Peor: solo compara dentro del mismo artículo. El modo de falla real de estos sistemas, que el modelo emita la misma brecha genérica para los diez artículos del lote, no se mide en absoluto.	Alta
M-06	Lista de palabras vacías insuficiente. services/metrics.py:515	Contiene unas 65 entradas mezclando español e inglés; una lista real de español tiene entre 300 y 600. La densidad léxica sale inflada y casi invariante, lo que agrega un tercer término cuasi-constante a la dimensión Síntesis y claridad.	Media
M-07	Ausencia total de referencia externa (ground truth). Transversal.	No existe ningún conjunto de brechas anotadas por expertos contra el cual contrastar. Sin él, la afirmación del artículo de que los resultados <i>confirman la fiabilidad del modelo</i> no tiene sustento: se está midiendo consistencia interna, no corrección. Es el bloqueante conceptual del proyecto.	Crítica
M-08	Una sola brecha por artículo. services/gemini_service.py	La función de análisis devuelve un único objeto, no una lista. La matriz resultante tiene N filas para N artículos. Un investigador espera varias brechas tipificadas por documento y la posibilidad de agruparlas transversalmente.	Alta

ID	Deficiencia y ubicación	Por qué es un problema	Sev.
M-09	Truncado agresivo del texto fuente. utils/text_extractor.py:9	La expresión regular corta todo el documento desde la primera aparición de la palabra <i>References</i> en cualquier posición, incluido el cuerpo del texto. Puede estar descartando la mayor parte de artículos sin que nada lo señale. Degrada silenciosamente todas las métricas aguas abajo.	Alta

Verificación inmediata sugerida (una consulta, sin tocar código)

Ejecutar sobre la base de datos actual: `SELECT estado_validacion, COUNT(*) FROM resultado_brecha GROUP BY estado_validacion;`

Si el resultado concentra casi todo en *aceptada* y prácticamente nada en *rechazada*, M-01 y M-04 quedan confirmados empíricamente sobre datos reales del proyecto. Es la forma más barata de cerrar la discusión antes de invertir tiempo en desarrollo.

3.2 Bloque S: seguridad, privacidad y modelo de negocio

Estas deficiencias son irrelevantes para una demostración académica controlada y absolutamente bloqueantes para cualquier despliegue con usuarios reales o cobro.

ID	Deficiencia y ubicación	Por qué es un problema	Sev.
S-01	Sin autenticación. Ningún endpoint exige credenciales.	Una petición a GET /proyectos devuelve todos los proyectos existentes. Cualquiera con la dirección del servidor lee y modifica el trabajo de todos.	Crítica
S-02	Sin multi-tenencia. El modelo de datos no tiene propietario.	No existe una entidad usuario ni una clave de pertenencia en proyecto. Es un cambio de esquema y de todas las consultas, por eso conviene resolverlo temprano y no después.	Crítica
S-03	Clave de API única y global. backend/.env	Todos los usuarios consumirían la misma clave sin cuota individual. Un solo usuario puede agotar el presupuesto de todos.	Crítica
S-04	Consumo no contabilizado. routers/runs.py y routers/estado_arte.py:78	Los campos tokens_in, tokens_out y costo_estimado existen en el esquema pero nunca se actualizan: quedan en cero. No se puede facturar lo que no se mide , ni detectar abuso, ni conocer el margen.	Crítica
S-05	CORS fijo en código. main.py:52	Solo admite localhost:5173. No hay configuración por entorno, por lo que cualquier despliegue exige editar y volver a publicar el código.	Media
S-06	Validación de subida insuficiente. routers/archivos.py:88	Solo se comprueba que el nombre termine en .pdf. No hay límite de tamaño ni verificación del contenido real. Superficie de abuso trivial y riesgo de agotamiento de disco.	Alta

3.3 Bloque A: arquitectura y escalabilidad

ID	Deficiencia y ubicación	Por qué es un problema	Sev.
A-01	Procesamiento síncrono bloqueante. routers/pipeline.py:71	Un bucle while True encadena llamadas al modelo dentro del propio request HTTP. Con diez PDFs se supera el tiempo de espera de cualquier proxy o navegador. El usuario no tiene forma de conocer el progreso ni de reanudar.	Crítica
A-02	Sin reintentos ni control de ritmo. routers/runs.py:277	Una respuesta 429 o un fallo transitorio marca el artículo como fallido de forma definitiva y el lote continúa. Se pierde trabajo por causas recuperables.	Alta
A-03	Almacenamiento en disco local. backend/storage/pdfs	Los PDFs no sobreviven a un redespigie en contenedor ni permiten más de una instancia del servicio.	Alta

ID	Deficiencia y ubicación	Por qué es un problema	Sev.
A-04	Búsqueda vectorial por fuerza bruta. <code>services/embedding_service.py:126</code>	Los vectores se guardan como JSON en MySQL y cada consulta carga todos los fragmentos a memoria para calcular coseno en Python. Funciona con diez artículos; no funciona con mil.	Alta
A-05	Sin migraciones versionadas. <code>main.py:40</code>	Se usa <code>create_all()</code> en el arranque. Ya existen divergencias entre <code>schema.sql</code> y los modelos, y no hay forma controlada de evolucionar el esquema en producción.	Alta
A-06	Sin paginación. Todos los listados.	Cada listado devuelve el conjunto completo. Degrada de forma lineal con el uso.	Media
A-07	Frontend monolítico sin enrutador. <code>frontend/src/App.jsx</code>	1033 líneas en un único archivo con navegación por estado local. No se puede compartir el enlace de un proyecto, ni recargar sin perder el contexto, ni crecer sin fricción.	Media

3.4 Bloque C: calidad de ingeniería y deuda técnica

ID	Deficiencia y ubicación	Por qué es un problema	Sev.
C-01	Cero pruebas automatizadas. Todo el repositorio.	No existe ningún archivo de prueba. Cualquier corrección de las métricas se hará a ciegas, sin red de seguridad para detectar regresiones. Es el prerrequisito de todo lo demás.	Crítica
C-02	Router duplicado. routers/batch.py frente a routers/runs.py	Ambos declaran el mismo prefijo y las mismas rutas y ambos se registran en main.py. Es código muerto que además omite la persistencia de resultado_resumen: si el orden de registro cambiara, se dejarían de guardar los resúmenes en silencio.	Alta
C-03	requirements.txt en UTF-16.	pip install -r falla. El proyecto no se puede instalar desde cero siguiendo su propia documentación.	Alta
C-04	Dependencias faltantes y OCR muerto. services/ocr_fallback.py	Faltan pdf2image y pytesseract. Además ningún módulo importa el archivo: el OCR nunca se ejecuta , pese a que la base de datos modela estados ocr y un campo ocr_aplicado. Los PDFs escaneados fallan sin recuperación.	Alta
C-05	schema.sql con sentencias destructivas. líneas 235 a 239	El archivo termina con un SELECT y tres DELETE FROM sin cláusula WHERE, restos de una sesión de Workbench. Ejecutar el archivo completo vacía las tablas.	Alta
C-06	Error tipográfico en la exportación. routers/export.py	Se lee es_duplicida en lugar de es_duplicada: esa columna sale siempre vacía en el CSV que se entrega al usuario.	Media
C-07	Divergencias entre esquema y modelos ORM.	estado_arte.run_id es NOT NULL en SQL y nullable en el modelo; Run.costo_estimado es DECIMAL(10,2) en SQL y sin tipo explícito en el ORM. Síntoma directo de A-05.	Media
C-08	Tablas modeladas sin uso. articulo_meta, rag_log	Previstas para caché de Crossref/Scopus y trazabilidad de recuperación, no tienen modelo ni endpoint. Funcionalidad prometida en el diseño y ausente en la implementación.	Media
C-09	Arranque condicionado a la clave de API. services/embedding_service.py:20	Se lanza una excepción en tiempo de importación si falta la clave. En consecuencia el modo simulado de gemini_service es inalcanzable y no se puede levantar el sistema para pruebas ni demostraciones sin consumir cuota.	Alta
C-10	Importación muerta. models/resultado_resumen.py	Importa el dialecto de PostgreSQL en un proyecto MySQL. Inocuo, pero indicativo del nivel de revisión del código.	Media

3.5 Bloque P: producto, cumplimiento y operación

ID	Deficiencia	Por qué es un problema	Sev.
P-01	Sin posición sobre derechos de autor y privacidad.	Los usuarios subirán artículos de suscripción que el sistema reenvía a un tercero. No hay términos de servicio, política de privacidad, plazo de retención ni consentimiento. Para un público académico e institucional esto es condición de entrada, no un detalle final.	Crítica
P-02	Resultados no reproducibles ni auditables.	No se registra qué versión de prompt ni qué versión de modelo produjo cada brecha. Un investigador no puede citar ni defender un resultado que no puede reproducir, y una actualización silenciosa del proveedor cambia las salidas sin dejar rastro.	Alta
P-03	Sin gestión de cuentas, planes ni facturación.	No existe registro, recuperación de acceso, planes, límites ni cobro. Es el trabajo propio de la Fase 4 y depende por completo de S-02 y S-04.	Alta
P-04	Sin observabilidad.	No hay registro estructurado, métricas de servicio ni alertas. Un fallo en producción se detectaría por el reclamo de un usuario.	Alta

SECCIÓN 4

Escala de madurez: qué significa cada nivel

Para que el objetivo *llegar al nivel 10* sea accionable, la escala se define en términos verificables. Un nivel se considera alcanzado únicamente cuando se cumplen todos sus criterios.

Nivel	Denominación	Criterios verificables
1 – 2	Prueba de concepto	Piezas sueltas que funcionan de forma aislada. No hay recorrido completo de principio a fin.
3	Prototipo funcional ESTADO ACTUAL	Recorrido completo operativo en un solo equipo y con un solo usuario. Demuestra la idea en condiciones controladas. Sin seguridad, sin pruebas, sin garantías sobre las cifras que reporta.
4 – 5	Prototipo saneado	Se instala limpio desde cero siguiendo el README. Sin código muerto ni duplicado. Esquema versionado con migraciones. Batería de pruebas que cubre el recorrido principal. Integración continua que ejecuta esas pruebas en cada cambio.
6	Plataforma multiusuario	Identidad y autorización. Aislamiento real entre cuentas verificado por pruebas. Procesamiento en segundo plano con progreso consultable, reintentos y reanudación. Despliegue reproducible en contenedores. Consumo de tokens y costo registrados por ejecución.
7	Métricas corregidas	ROUGE calculado contra el abstract real. Entropía de caracteres sustituida por una medida efectiva de coherencia. Umbrales recalibrados sobre distribuciones observadas. Detección de duplicados operativa e inter-artículo. Varias brechas por documento.
8	Sistema validado	Conjunto de referencia anotado por expertos. Precisión, exhaustividad y F1 del sistema medidos contra ese consenso. Acuerdo entre anotadores reportado. Resultados publicados o publicables.
9	Producto operable	Cuentas, planes y cuotas aplicadas. Facturación funcionando. Observabilidad con alertas. Copias de seguridad y procedimiento de recuperación probado. Documentación de usuario.
10	Comercializable	Términos de servicio y política de privacidad vigentes. Posición resuelta sobre derechos de autor. Canal de soporte. Evidencia pública de validación que un investigador pueda citar. Compromiso de disponibilidad sostenible.

Por qué hoy es 3 y no más

El sistema hace lo que promete de principio a fin, y eso vale. Pero no se instala desde cero (C-03), no tiene una sola prueba (C-01), expone todos los datos a cualquiera (S-01), se bloquea con diez PDFs (A-01), no puede facturar (S-04) y sus cifras de calidad no discriminan (M-01, M-04, M-07). Cada uno de esos puntos, por sí solo, impide cobrar por el servicio.

SECCIÓN 5

Ruta de implementación por fases

Las fases están ordenadas por dependencia, no por preferencia. Adelantar la Fase 3 sin cerrar la Fase 1 significa corregir métricas sin pruebas que detecten regresiones. Adelantar la Fase 4 sin la Fase 2 significa construir facturación sobre un sistema que no sabe quién es cada usuario.

FASE 0 — Acuerdo, alcance y diseño	Nivel 3	1 a 2 semanas
Objetivo. Cerrar las decisiones de la Sección 7 antes de escribir una sola línea. Ninguna tarea de esta fase produce código. Entregables • Confirmar empíricamente M-01 y M-04 con la consulta de la Sección 3.1 sobre datos reales. • Decidir modelo de negocio: producto comercial propio frente a licencia institucional. • Decidir destino del almacenamiento vectorial (permanecer en MySQL o migrar). • Definir quién anota el conjunto de referencia y con qué disponibilidad de tiempo. • Acordar si se publica una versión corregida o una fe de erratas del artículo. • Documento de arquitectura objetivo y modelo de datos con propietario de cada recurso. Criterio de cierre. Este documento aprobado por ambas partes, con las seis decisiones resueltas por escrito.		
FASE 1 — Saneamiento técnico	Nivel 3 a 5	2 a 3 semanas
Objetivo. Dejar el proyecto instalable, probado y sin deuda evidente. Es la red de seguridad que permite tocar las métricas sin romper nada en silencio. Entregables • Corregir C-03 (codificación) y C-05 (sentencias destructivas en el esquema). • Eliminar routers/batch.py y las importaciones muertas (C-02, C-10). • Reparar C-06 (error tipográfico), C-07 (divergencias ORM) y C-09 (arranque sin clave de API). • Activar el OCR de respaldo o retirar formalmente su modelado de la base de datos (C-04). • Corregir M-09: el truncado por la palabra <i>References</i> debe anclarse a inicio de línea y aplicarse solo en el último tercio del documento. • Introducir Alembic y convertir el esquema en migraciones versionadas (A-05). • Batería de pruebas: unitarias sobre services/metrics.py con valores esperados fijos, e integración del recorrido completo con el modelo simulado. • Integración continua que ejecute las pruebas en cada cambio. • README con instalación verificada desde cero en una máquina limpia. Criterio de cierre. Un tercero clona el repositorio, sigue el README y obtiene el sistema funcionando; las pruebas pasan en verde en integración continua.		

FASE 2 — Plataforma multiusuario	Nivel 5 a 6	3 a 4 semanas
Objetivo. Convertir la aplicación de un solo usuario en un servicio con cuentas aisladas capaz de procesar cargas reales sin bloquearse. Entregables • Autenticación y autorización; entidad usuario y clave de propietario en proyecto (S-01, S-02). • Pruebas de aislamiento: verificar que la cuenta A no puede leer ni modificar recursos de la cuenta B. • Cola de trabajos en segundo plano sustituyendo el bucle síncrono, con estado consultable, reintentos con espera progresiva y reanudación (A-01, A-02). • Contabilidad real de tokens y costo por ejecución, poblando los campos que hoy quedan en cero (S-04). • Almacenamiento de objetos externo al contenedor y límites de tamaño en la subida (A-03, S-06). • CORS y configuración por variables de entorno (S-05); paginación en los listados (A-06). • Enrutador en el frontend y división del archivo único en módulos (A-07). • Empaquetado en contenedores y despliegue reproducible. Criterio de cierre. Dos cuentas distintas trabajan en paralelo sin verse; un lote de veinte PDFs se procesa sin agotar el tiempo de espera y muestra progreso; el costo de cada ejecución queda registrado.		
FASE 3 — Corrección y validación metodológica	Nivel 6 a 8	6 a 8 semanas
Objetivo. Hacer que las métricas midan lo que dicen medir, y demostrarlo contra juicio experto. Es el núcleo del valor del producto y el único tramo que no se acelera contratando más desarrollo. Entregables • M-02: extraer el abstract real del PDF y usarlo como referencia de ROUGE. Añadir ROUGE-2 y ROUGE-L. • M-01: sustituir la entropía de caracteres por una medida efectiva de coherencia (similitud entre oraciones consecutivas o perplejidad de un modelo de lenguaje). • M-03: renombrar la similitud coseno como indicador de <i>anclaje a la fuente</i> y separarla conceptualmente de la calidad de la brecha, que pasa a medirse contra el juicio experto. • M-04: recalibrar todos los umbrales sobre la distribución real observada, no sobre valores supuestos. • M-05: detección de duplicados por similitud de embeddings y con alcance inter-artículo. • M-06: lista de palabras vacías completa y separada por idioma. • M-08: permitir varias brechas tipificadas por artículo y su agrupación transversal. • P-02: registrar versión de prompt y de modelo en cada resultado, para reproducibilidad. • M-07: construcción del conjunto de referencia y campaña de evaluación (Sección 6). Criterio de cierre. Se reporta precisión, exhaustividad y F1 del sistema contra el consenso experto, junto con el acuerdo entre anotadores. Las cifras son defendibles ante un revisor externo.		
FASE 4 — Producto	Nivel 8 a 10	6 a 8 semanas
Objetivo. Envolver un sistema ya confiable en la operación, el cumplimiento y el soporte que exige cobrar por él. Entregables • Planes, cuotas aplicadas y pasarela de pago apoyadas en la contabilidad de la Fase 2 (P-03). • Observabilidad: registro estructurado, métricas de servicio, alertas, copias de seguridad y recuperación probada (P-04). • Términos de servicio, política de privacidad, plazo de retención y consentimiento explícito para el envío de documentos a terceros (P-01). • Registro, recuperación de acceso, incorporación guiada y documentación de usuario. • Canal de soporte y publicación de la evidencia de validación obtenida en la Fase 3. Criterio de cierre. Un investigador externo se registra, contrata un plan, procesa su propio corpus, obtiene resultados reproducibles y dispone de respaldo documental sobre cómo se validaron.		

SECCIÓN 6

Plan de validación metodológica (núcleo de la Fase 3)

Esta sección merece desarrollo aparte porque resuelve la observación del profesor sobre *entrenamiento del modelo* y porque es lo único que separa una demostración convincente de una herramienta en la que un investigador confía su trabajo.

6.1 Por qué no aplica el marco clásico de entrenamiento

El sistema **no entrena ni ajusta ningún modelo**. Emplea un modelo de lenguaje de terceros mediante instrucciones estructuradas con ejemplos incorporados en el propio mensaje, y un modelo de embeddings para la recuperación. No hay gradientes, no se actualizan pesos y no existe división entre entrenamiento y prueba. Por eso no aplican el sobreajuste, la validación cruzada ni las curvas de aprendizaje: no hay nada que aprenda.

Pero la conclusión no es que no haya que evaluar. La evaluación sigue siendo obligatoria y cambia de objeto: **se evalúan las salidas del sistema, no los pesos de un modelo**. Y ahí la precisión y la exhaustividad recuperan pleno sentido, medidas contra juicio humano.

Concepto clásico	Equivalente en un sistema de IA generativa con recuperación
Conjunto de entrenamiento	No existe. Los ejemplos incluidos en el mensaje no modifican el modelo.
Conjunto de prueba	Conjunto de referencia anotado por expertos, reservado y nunca usado para ajustar instrucciones.
Precisión	De las brechas que el sistema propuso, qué proporción validó un experto como legítima.
Exhaustividad (recall)	De las brechas que los expertos identificaron, qué proporción encontró el sistema.
Sobreajuste	Ajuste excesivo de las instrucciones a los mismos documentos con los que se evalúa.
Fiabilidad del etiquetado	Acuerdo entre anotadores mediante kappa de Cohen o de Fleiss.
Verificación de alucinación	Fidelidad a la fuente: toda afirmación debe ser rastreable a un fragmento recuperado.

6.2 Protocolo propuesto

Elemento	Especificación
Corpus	De 40 a 50 artículos repartidos en 3 a 5 dominios distintos, todos con abstract disponible y publicación reciente. Se busca variedad deliberada, no homogeneidad.
Anotadores	De 2 a 3 personas con formación en investigación. Trabajan de forma independiente y sin ver las salidas del sistema, para evitar sesgo de anclaje.
Procedimiento	Cada anotador identifica y tipifica las brechas de cada artículo. Se consolida un consenso por discusión sobre las discrepancias. Ese consenso es la referencia.
Métricas del sistema	Precisión, exhaustividad y F1 frente al consenso. Adicionalmente, exactitud de la tipificación (metodológica, temática, teórica, tecnológica).
Fiabilidad	Kappa de Cohen con dos anotadores o de Fleiss con tres o más. Objetivo mínimo: 0.60, que corresponde a acuerdo sustancial.
Métricas técnicas	ROUGE-1, ROUGE-2 y ROUGE-L contra el abstract real. Fidelidad a la fuente. Coherencia inter-oracional. Densidad léxica con lista completa.
Escalado	Un evaluador automático basado en modelo de lenguaje, calibrado contra el consenso humano y reportando su correlación, para extender la evaluación más allá de los 50 documentos.
Umbral de éxito	Precisión igual o superior a 0.70 y exhaustividad igual o superior a 0.50. Por debajo de esos valores el sistema no está listo para cobrarse.

Advertencia honesta sobre el resultado esperado

Al corregir las métricas es probable que varios indicadores **empeoren** respecto de lo publicado. Eso no es un retroceso: es la señal de que por fin están midiendo algo. Un 65% de calidad global que se mueve según la entrada vale infinitamente más que un 65% que sale igual pase lo que pase. Conviene acordar de antemano que esa caída es el resultado buscado, para que no se lea como fracaso.

SECCIÓN 7

Decisiones abiertas que requieren acuerdo

Ninguna de estas decisiones puede tomarse desde el código: todas cambian el alcance, el presupuesto o el orden de las fases. Son el contenido de la Fase 0.

#	Decisión	Por qué importa	Afecta a
1	Producto comercial propio o licencia institucional a universidades y grupos de investigación.	Cambia por completo el peso de la Fase 4. Una licencia institucional con instalación en servidores del cliente reduce drásticamente la exposición legal de P-01.	Fase 4, P-01
2	Proveedor único o multi-modelo. El artículo ya lo lista como trabajo futuro.	Soportar varios proveedores permite comparación de arquitecturas, que es una contribución científica reclamada en las limitaciones del artículo, pero multiplica el esfuerzo de abstracción y de pruebas.	Fase 3
3	Permanecer en MySQL con vectores en JSON o migrar a una base con soporte vectorial nativo.	Determina si el sistema soporta corpus grandes. Es más barato decidirlo ahora que después de construir sobre la solución actual.	A-04, Fase 2
4	Quién anota el conjunto de referencia y con qué disponibilidad.	Es la ruta crítica de la Fase 3 y el único recurso que no se puede sustituir con desarrollo. Sin anotadores comprometidos, el nivel 8 es inalcanzable.	M-07, Fase 3
5	Publicar o no una versión corregida del artículo con las métricas revisadas.	Afecta la credibilidad académica del proyecto. Corregir de forma proactiva la interpretación de la entropía y del ROUGE es más sólido que esperar a que lo señale un revisor.	Transversal
6	Servicio alojado propio o instalación en el cliente.	Determina quién custodia los PDFs con derechos de autor. La instalación en el cliente traslada esa responsabilidad y simplifica enormemente el cumplimiento.	P-01, Fase 4

7.1 Riesgos identificados

Riesgo	Mitigación propuesta
Los resultados empeoran al corregir las métricas y se lee como retroceso.	Acordarlo por escrito de antemano y enmarcarlo como corrección metodológica. Conservar las cifras antiguas y las nuevas lado a lado para explicar la diferencia.
Costo de API sin acotar en producción.	La contabilidad de consumo (S-04) y las cuotas deben estar operativas antes de abrir el registro público, no después.
Derechos de autor sobre los PDFs que suben los usuarios.	Resolver la decisión 6. La instalación en servidores del cliente o el procesamiento efímero sin retención reducen la exposición de forma sustancial.
Dependencia de un único proveedor de modelo.	Abstraer la capa de generación detrás de una interfaz propia durante la Fase 3, aunque inicialmente solo tenga una implementación.
No conseguir anotadores para el conjunto de referencia.	Reducir el alcance a 25 o 30 artículos en un solo dominio antes que renunciar a la validación. Un conjunto pequeño y honesto vale más que ninguno.
Alcance creciente que impide cerrar fases.	Criterios de cierre verificables por fase, ya definidos en la Sección 5. No se inicia una fase sin haber cerrado formalmente la anterior.

Cierre

El proyecto está bien encaminado en lo estructural: la arquitectura resuelve correctamente un problema real y la metodología DSRM está bien aplicada en sus fases de identificación, objetivos, diseño, demostración y comunicación. La debilidad se concentra en la fase de evaluación, que es precisamente donde reside el valor comercial. Corregirla no exige reescribir el sistema: exige cambiar qué se mide, contra qué se compara y cómo se interpreta el resultado.

El siguiente paso propuesto es la Fase 0. No requiere escribir código y comienza por la consulta de verificación de la Sección 3.1, que sobre datos reales del proyecto confirma o refuta el diagnóstico central de este documento en menos de un minuto.