

Matriz Capstone

Documentación técnica integral

Guía para comprender, ejecutar, mantener y evolucionar el sistema de análisis de brechas de investigación.

Edición	1.0
Fecha de corte	2 de septiembre de 2026
Código revisado	commit e540d82 - rama CarlosDev
Estado	Construcción funcional terminada; mejoras metodológicas y operativas pendientes
Audiencia	Desarrolladores, mantenedores e investigadores técnicos

Este PDF describe el estado comprobable del repositorio. Los datos privados del servidor y su archivo .env no forman parte del documento.

Índice

Las secciones siguen el recorrido que necesita una persona nueva: primero el propósito, después la arquitectura, luego el flujo y finalmente operación, métricas y evolución.

Índice	2
1. Visión general	5
1.1 Problema que resuelve	5
1.2 Límites del producto	5
1.3 Estado de la edición	5
2. Arquitectura del sistema	6
2.1 Tecnologías principales	6
2.2 Responsabilidad de Docker y Oracle	6
2.3 Servicios de Docker Compose	7
3. Flujo funcional y de procesamiento	8
3.1 Recorrido del usuario	8
3.2 Etapas internas	8
3.3 Cola de trabajos y tolerancia a fallos	9
4. Organización del código	10
4.1 Backend	10
4.2 Frontend	10
4.3 Mapa de API	11
5. Modelo de datos y persistencia	12
5.1 Relaciones esenciales	12
5.2 Migraciones vigentes	13
5.3 Archivos y deduplicación	13

6. RAG, generación y verificación	14
6.1 Recuperación	14
6.2 Tipos de afirmación	14
6.3 Modos de ejecución	14
7. Sistema de medición N0-N6	15
7.1 Reglas de lectura	15
7.2 Mapa de niveles	15
7.3 N0 - Calidad de ingesta	15
7.4 N1 - Recuperación	16
7.5 N2 - Fidelidad y trazabilidad	16
7.6 N3 - Especificidad	16
7.7 N4 - Resumen	16
7.8 N5 - Tipificación y síntesis	17
7.9 N6 - Anclaje humano	17
7.10 Evidencia piloto	17
8. Seguridad, propiedad y cuota	18
8.1 Cuota de Gemini	18
8.2 Riesgos todavía declarados	18
9. Ejecución, despliegue y operación	19
9.1 Entornos	19
9.2 Actualización manual	19
9.3 Caddy y red	19
9.4 Persistencia y respaldos	19
10. Pruebas, integración continua y diagnóstico	20

10.1 Qué protegen especialmente las pruebas	20
10.2 Diagnóstico operativo	20
11. Mejoras pendientes y orden recomendado	21
11.1 Dependencias metodológicas	21
11.2 Límites que deben declararse	21
12. Política de cambios y nuevas ediciones del PDF	22
12.1 Cambios que obligan a avisar	22
13. Guía de incorporación para otro desarrollador	23
13.1 Orden de lectura	23
13.2 Arranque seguro	23
13.3 Lista antes de aprobar un cambio	23
14. Fuentes del repositorio y glosario	24
14.1 Fuentes principales	24
14.2 Glosario	24

1. Visión general

Matriz Capstone es una herramienta de apoyo a la investigación que transforma artículos científicos en una matriz de brechas y un borrador de estado del arte. Su aporte no es solo generar texto: conserva trazabilidad hacia los PDF, verifica afirmaciones y expone métricas que permiten inspeccionar la calidad del proceso.

1.1 Problema que resuelve

Un investigador necesita identificar qué hizo cada artículo, qué limitaciones declara y qué oportunidades permanecen abiertas. Hacerlo manualmente exige leer, comparar y sintetizar numerosos PDF. El sistema automatiza una primera lectura estructurada, pero entrega borradores verificables, no conclusiones científicas definitivas.

- Organiza artículos por proyecto y conserva DOI, título y PDF original.
- Extrae texto, detecta secciones y usa OCR cuando el PDF es una imagen.
- Recupera fragmentos relevantes por significado y no solo por palabras exactas.
- Genera una brecha y una oportunidad por artículo, con evidencia rastreable.
- Verifica afirmaciones, contradicciones y brechas que el propio artículo ya resolvió.
- Sintetiza el conjunto en un estado del arte y permite exportarlo.
- Permite una revisión humana ciega para contrastar los resultados automáticos.

1.2 Límites del producto

La aplicación es una herramienta de apoyo personal y un proyecto capstone basado en DSRM. No reemplaza la lectura crítica, no certifica verdad científica, no evalúa la calidad metodológica completa de un artículo y no debe presentarse como árbitro automático. La anotación humana N6 es la referencia para saber si una brecha resulta correcta para un investigador.


1.3 Estado de la edición

Aspecto	Estado registrado
Código	Commit e540d82; ramas main y CarlosDev alineadas según el contexto vigente
Base	MySQL 8 con migraciones Alembic 0001 a 0009
Pruebas	448 pruebas en verde contra MySQL real, según CI #64 documentado
N6	Piloto 5/5: tres correctas y dos parciales; acierto ponderado 0.80
Despliegue	Oracle Cloud Always Free, Docker Compose, Caddy y HTTPS
Trabajo restante	Mejoras metodológicas, pruebas de frontend, respaldo externo y calibración

La cifra de pruebas y el estado del CI se reproducen desde la documentación actual del repositorio; este PDF no volvió a ejecutar la suite completa.

2. Arquitectura del sistema

La arquitectura separa la interacción web, el procesamiento largo, la persistencia y los servicios de IA. Docker empaqueta y coordina; Oracle Cloud aloja la máquina que permanece encendida.



2.1 Tecnologías principales

Capa	Tecnología	Responsabilidad
Frontend	React 19, React Router 7, Vite 7, Tailwind 4	Pantallas, sesión, navegación y consumo de la API
API	FastAPI 0.124, Pydantic 2	Contratos HTTP, autenticación, proyectos, resultados y exportaciones
Persistencia	SQLAlchemy 2, PyMySQL, MySQL 8	Datos de negocio, cola, métricas y trazabilidad
Migraciones	Alembic	Única fuente de verdad para crear y evolucionar el esquema
IA	Gemini 2.5 Flash y gemini-embedding-001	Generación, verificación semántica y embeddings
PDF/OCR	PyMuPDF, pdfminer, Tesseract	Extracción de texto y respaldo para documentos escaneados
Servidor web	Caddy 2	Estáticos, proxy /api, SPA, compresión y certificados TLS
Infraestructura	Docker Compose sobre Ubuntu en Oracle Cloud	Ejecución reproducible y disponibilidad permanente

2.2 Responsabilidad de Docker y Oracle

Elemento	Qué hace	Qué no hace
Docker	Construye imágenes, aísla dependencias, coordina servicios y conserva volúmenes.	No es el proveedor de alojamiento ni publica por sí solo la aplicación en Internet.
Oracle Cloud	Proporciona la VM Ubuntu, red, IP pública, CPU, RAM y disco persistente.	No conoce la lógica interna de FastAPI o React; ejecuta Docker como cualquier servidor Linux.
Caddy	Recibe 80/443, obtiene TLS, sirve el frontend y reenvía /api al backend.	No procesa análisis ni guarda resultados científicos.


2.3 Servicios de Docker Compose

Servicio	Ciclo de vida	Datos o dependencia clave
mysql	Permanente; healthcheck antes de continuar	Volumen datos_mysql
migraciones	Se ejecuta una vez y termina	alembic upgrade head
backend	Permanente; Uvicorn	MySQL, JWT y volumen pdfs
trabajador	Permanente; consume la cola	Mismo código e imagen que backend; comparte pdfs
frontend	Permanente; Caddy	Estáticos compilados, puertos 80/443 y certificados

El servicio de migraciones es la quinta pieza del Compose, aunque en tiempo normal quedan cuatro servicios permanentes. Los comentarios antiguos que mencionan nginx son históricos: el servidor vigente es Caddy.

3. Flujo funcional y de procesamiento

El usuario dispara un análisis corto desde la web, pero el trabajo pesado ocurre en segundo plano. La API no espera minutos ni depende del tiempo máximo de un proxy.



3.1 Recorrido del usuario

Paso	Acción	Resultado
1	Iniciar sesión	JWT válido y acceso solo a proyectos propios
2	Crear proyecto	Tema, objetivo, metodología, sector y cantidad esperada
3	Subir PDF	Artículo, archivo, hash, título y DOI; deduplicación dentro del proyecto
4	Analizar	Se crea un run y un run_item por artículo; la API responde sin bloquear
5	Esperar progreso	El frontend consulta estados mientras el trabajador procesa
6	Revisar resultados	Brecha, oportunidad, métricas, síntesis y consumo
7	Revisar a ciegas	Veredicto humano sin ver antes la nota automática
8	Exportar	Matriz PDF/JSON, brechas CSV, estado del arte MD y panel PDF

3.2 Etapas internas

Ingesta

PyMuPDF intenta extraer texto; pdfminer actúa como alternativa y Tesseract como respaldo. Se limpia el documento, se corta la bibliografía por encabezado y se calculan N0.1-N0.4.

Estructura

Se identifican resumen, introducción, método, resultados, discusión, limitaciones, conclusiones y referencias. La sección acompaña a cada fragmento.

Indexado

El texto se fragmenta y cada bloque recibe un embedding de 768 dimensiones derivado de gemini-embedding-001.

Recuperación

La consulta combina objetivo, tema y contexto del proyecto. Se puntúan fragmentos por similitud, se aplica diversidad MMR y una cuota por sección.

Análisis

Gemini produce tipo de brecha, brecha, oportunidad, evidencia y resumen. El resultado conserva los fragmentos RAG que sustentaron la generación.

Verificación

La brecha se divide en afirmaciones evidenciales e inferenciales. Se revisan respaldo, cita, contradicción y si el artículo ya resolvió lo presentado como pendiente.

Síntesis

Al cerrar la ejecución, si fue solicitada, se genera una versión del estado del arte vinculada al run actual.

Medición

Las métricas locales y las que requieren verificador se guardan en formato largo. N6 se añade mediante revisión humana.

3.3 Cola de trabajos y tolerancia a fallos

Regla	Comportamiento
Reserva	SELECT ... FOR UPDATE SKIP LOCKED evita que dos trabajadores tomen el mismo artículo.
Reintentos	Hasta tres intentos para fallos transitorios; los definitivos terminan inmediatamente.
Abandono	Un item en proceso por más de 15 minutos puede recuperarse por otro trabajador.
Cuota diaria	El item vuelve a pendiente sin consumir intento y el trabajador espera el reinicio.
Cierre	Otro ciclo detecta runs sin items pendientes y los cierra, incluso si murió quien procesó el último.
Escala	Se pueden levantar varios trabajadores; MySQL coordina la exclusión.

4. Organización del código

El repositorio está organizado por responsabilidades. El punto crítico para un mantenedor es no duplicar fuentes de verdad: Alembic gobierna el esquema y el catálogo de métricas gobierna nombres e interpretación.

```
docker-compose.yml orquestación local y de servidor
respaldar.sh volcado diario y rotación
backend/main.py aplicación FastAPI y routers
backend/trabajador.py consumidor de la cola
backend/migraciones/ evolución oficial del esquema
backend/app/models/ 15 tablas de dominio
backend/app/routers/ endpoints HTTP
backend/app/services/ RAG, IA, verificación, métricas y cuota
backend/app/utils/ extracción de texto
backend/tests/ pruebas automáticas
frontend/src/App.jsx rutas y pantallas principales
frontend/src/sesion.js token y cliente de API
frontend/src/index.css sistema visual
frontend/Caddyfile web, proxy y HTTPS
docs/ contexto, metodología y operación
```

4.1 Backend

backend/main.py valida la configuración, comprueba la revisión de Alembic, registra CORS y monta los routers. No crea tablas con SQLAlchemy: cualquier cambio de esquema necesita una migración. Los routers resuelven propiedad mediante dependencias compartidas y delegan el trabajo técnico a servicios.

4.2 Frontend

Ruta	Pantalla
/	Bienvenida e ingreso
/proyectos	Listado y lectura rápida del estado
/proyectos/nuevo	Creación de proyecto
/proyectos/:id/articulos	Carga, listado y eliminación de PDF
/proyectos/:id/brechas	Resultados, métricas, artículos y exportaciones
/proyectos/:id/revisar	Revisión humana ciega y apertura del PDF

Vite incrusta VITE_API_BASE durante la compilación. Por eso editar App.jsx en la laptop no cambia el sitio público y un despliegue del frontend exige reconstruir la imagen con --build.

4.3 Mapa de API

Grupo	Operaciones principales
Autenticación	POST /auth/registro, POST /auth/login, GET /auth/yo, POST /auth/renovar
Proyectos	Crear, listar y obtener; dashboard y consumo
Artículos/PDF	Subir, listar, eliminar, abrir PDF autenticado
Ejecuciones	Crear/listar run, run activo, items, progreso y procesamiento
Pipeline	POST /proyectos/{id}/analizar_todo
Brechas	Consultar por artículo y reverificar fidelidad
Métricas	Resumen, series, catálogo v2, por artículo y gráficos
Estado del arte	Generar y obtener última versión
N6	Leer progreso, guardar/eliminar veredicto y revelar comparación al completar
Exportación	CSV, MD, panel PDF, matriz JSON y matriz PDF

En producción el navegador usa /api. Caddy elimina ese prefijo antes de reenviar la petición a FastAPI.

5. Modelo de datos y persistencia

Hay 15 tablas funcionales declaradas por SQLAlchemy, más alembic_version. Los datos históricos se conservan: reanalizar crea nuevas ejecuciones y resultados en lugar de sobrescribir el pasado.

Tabla	Función
usuario	Cuenta, correo, contraseña cifrada y estado
proyecto	Tema y parámetros de investigación; dueño de la información
articulo	Registro bibliográfico dentro de un proyecto
archivo	PDF, hash, tamaño, estado y clave de almacenamiento
articulo_meta	Metadatos auxiliares del artículo
run	Ejecución completa, progreso, tokens, coste y síntesis solicitada
run_item	Estado e intentos de un artículo dentro de un run
embedding_doc	Fragmentos, sección, orden y vector
rag_log	Trazabilidad de la recuperación
resultado_brecha	Brecha, oportunidad, evidencia, tipo y rag_hits
resultado_resumen	Resumen generado por artículo
estado_arte	Síntesis versionada y asociada a una ejecución
metrica	Formato largo: código, ámbito, referencia, valor y detalle
llamada_api	Consumo, modelo, operación, tokens, éxito y motivo
validacion_humana	Veredicto N6 por persona y brecha, justificación y origen

5.1 Relaciones esenciales

- usuario -> proyecto: define el aislamiento entre cuentas.
- proyecto -> artículo y run: separa corpus y ejecuciones.
- run -> run_item -> resultado_brecha: conserva la historia de cada análisis.
- artículo -> archivo y embedding_doc: vincula la fuente física con su índice semántico.
- proyecto/referencia -> metrica: permite métricas por brecha, artículo, run o proyecto.
- resultado_brecha + usuario -> validacion_humana: permite más de un juez sin mezclar juicios.

5.2 Migraciones vigentes

Revisión	Cambio principal
0001	Esquema inicial completo
0002	Alineación de llamada_api
0003	Usuarios
0004	Dueño del proyecto
0005	Cola de trabajos
0006	ROUGE sin valor cuando no aplica
0007	Hash único por proyecto
0008	Validación humana
0009	Origen de la validación

database/schema.sql es referencia de lectura. Ejecutarlo sobre una base existente puede romper la historia de Alembic y no es un mecanismo de actualización.

5.3 Archivos y deduplicación

Los PDF se guardan con una clave relativa usuario/uuid.pdf detrás de una interfaz de almacenamiento. Backend y trabajador comparten el volumen pdfs. Las claves se validan para impedir recorridos fuera de la carpeta. El hash SHA-256 evita duplicados dentro del mismo proyecto, pero permite que el mismo artículo exista en otro proyecto o cuenta. Al eliminar un artículo se borran su PDF y sus datos asociados mediante relaciones en cascada.

6. RAG, generación y verificación

La lógica central evita que el modelo trabaje con el PDF entero sin control. Selecciona contexto, conserva los fragmentos usados y separa hechos verificables de inferencias.

6.1 Recuperación

Mecanismo	Razón
Embeddings	Permiten buscar cercanía de significado.
Similitud coseno	Ordena candidatos por relevancia semántica.
MMR	Reduce fragmentos repetidos y equilibra relevancia/diversidad.
Cuota por sección	Evita que resumen e introducción ocupen toda la ventana.
Orden documental final	Entrega los fragmentos en una secuencia más legible para el modelo.
rag_hits	Guarda qué fragmentos sustentaron el resultado.

La búsqueda vectorial carga embeddings desde MySQL y calcula similitud en Python. Es razonable para proyectos de 5 a 10 artículos; si el corpus crece mucho, primero debe medirse latencia antes de introducir un motor vectorial adicional.

6.2 Tipos de afirmación

Clase	Ejemplo conceptual	Tratamiento
Evidencial	El artículo usó una muestra de 50 casos.	Debe poder respaldarse y citarse en un fragmento.
Inferencial	Esto limita la generalización.	No se exige que sea frase literal, pero puede ser contradictoria con el artículo.
Dependiente	Esto reduce su fiabilidad.	Si perdió el sujeto al descomponerse, se excluye de ciertas tasas y se reporta en el detalle.

6.3 Modos de ejecución

Modo	Uso	Comportamiento
mock	Desarrollo, CI y demostraciones sin cuota	Textos deterministas; verificaciones que requieren juicio real quedan no disponibles cuando corresponde.
real	Evaluación con artículos	Usa Gemini, registra llamadas y queda sujeto a límites de minuto y día.

Cambiar modelo, prompt, fragmentación o recuperación puede alterar los resultados aunque el código de la métrica no cambie. Por eso estas variables deben formar parte del versionado metodológico pendiente.

7. Sistema de medición N0-N6

N# es una capa del proceso y N#.x es un indicador. El catálogo visible contiene 23 métricas automáticas de N1 a N5; N0 es diagnóstico operativo y N6 es juicio humano.

7.1 Reglas de lectura

Regla	Interpretación
Mediana	Valor central resistente a casos extremos; no es promedio.
P25/P75	Límites del 50 % central de los artículos.
IQR	P75 menos P25; describe dispersión, no calidad.
n	Cantidad realmente medida; una muestra de uno no permite hablar de variación.
Sin valor	No se midió o no aplica. No equivale a cero.
Dirección	Mayor, menor o descriptiva; no todas las métricas se leen igual.
Umbral	No existe un corte universal de calidad calibrado para este dominio.

7.2 Mapa de niveles

Nivel	Pregunta
N0 Ingesta	¿El PDF se convirtió en texto utilizable?
N1 Recuperación	¿Qué partes del artículo llegaron al modelo?
N2 Fidelidad	¿Lo que afirma la brecha se sostiene en la fuente?
N3 Especificidad	¿La brecha es concreta y distinta para ese artículo?
N4 Resumen	¿Cómo se relaciona el resumen con el abstract?
N5 Síntesis	¿La integración cubre las brechas y evita citas ajenas?
N6 Humano	¿Un investigador considera correcta la brecha?

7.3 N0 - Calidad de ingesta

Código	Qué mide	Lectura
N0.1	Caracteres extraídos frente a una estimación por páginas.	Cobertura técnica; el mínimo utilizable actual es 0.25.
N0.2	Texto final frente a texto bruto.	Un valor muy bajo avisa que la limpieza eliminó demasiado.
N0.3	Secciones reconocidas.	Conjunto diagnóstico, no una nota única.
N0.4	Proporción normalizada de palabras funcionales.	Detecta ruido u OCR degradado; mínimo utilizable 0.60.

Además se exige al menos 300 caracteres finales. N0 todavía no aparece dentro del catálogo de 23 métricas del panel.

7.4 N1 - Recuperación

Código	Indicador	Escala/dirección	Qué significa
N1.2	Cobertura seccional	0 a 1; mayor	Secciones sustantivas presentes en el contexto. El denominador actual es teórico y requiere v2.
N1.3	Diversidad del contexto	0 a 1; mayor	Uno menos la similitud media entre fragmentos recuperados.

7.5 N2 - Fidelidad y trazabilidad

Código	Indicador	Dirección	Qué significa
N2.1	Fidelidad evidencial	Mayor	Afirmaciones evidenciales autónomas respaldadas. No decide la corrección total de la brecha.
N2.2	Trazabilidad	Mayor	Afirmaciones con fragmento y cita. El denominador actual incluye inferencias y debe corregirse.
N2.4	Composición evidencial	Descriptiva	Proporción de hechos frente a inferencias; ningún extremo es universalmente mejor.
N2.5	Contradicciones	Menor	Afirmaciones a las que la fuente lleva la contraria.
N2.6	Brecha ya resuelta	Menor	Marca si se pide como pendiente algo que el artículo ya hizo.
N2.verificada	Verificación realizada	Mayor	Distingue medición ejecutada de ausencia de medición.

7.6 N3 - Especificidad

Código	Indicador	Escala/dirección	Qué significa
N3.1	Discriminabilidad	0 a 1; mayor	Diferencia semántica media entre brechas de artículos distintos.
N3.2	Densidad de anclajes	por 100 palabras; mayor	Cifras, siglas, nombres y vocabulario metodológico.
N3.3	Contenido informativo	IDF medio; mayor	Rareza de términos dentro del corpus del proyecto.
N3.4	Redundancia	0 a 1; menor	Brechas casi idénticas. La fórmula v2 marca ambos miembros y fija el orden.

7.7 N4 - Resumen

Código	Indicador	Lectura
N4.1a	ROUGE-1 precisión	Palabras del resumen que aparecen en el abstract.
N4.1b	ROUGE-1 recall	Palabras del abstract recuperadas en el resumen.
N4.1c	ROUGE-1 F1	Equilibrio de precisión y recall de palabras.
N4.1d	ROUGE-2 F1	Solape de pares de palabras consecutivas.
N4.1e	ROUGE-L F1	Subsecuencia común más larga.
N4.2	Similitud semántica	Cercanía de significado; funciona entre idiomas.
N4.4	Densidad léxica	Proporción de palabras con contenido; descriptiva.
N4.ref	Abstract localizado	Confirma si existe referencia real para ROUGE.

ROUGE solo se calcula cuando resumen y abstract están en el mismo idioma reconocido. Si están en idiomas distintos o falta abstract, el valor queda no aplicable. La densidad léxica sí puede medirse con solo el resumen.

7.8 N5 - Tipificación y síntesis

Código	Indicador	Dirección	Qué significa
N5.2	Reetiquetado automático	Descriptiva	Frecuencia con la que una heurística cambia el tipo asignado por el modelo.
N5.3	Cobertura de síntesis	Mayor	Brechas representadas semánticamente en el estado del arte.
N5.5	Citas sin correspondencia	Menor	Referencias de la síntesis no vinculables a artículos del proyecto.

7.9 N6 - Anclaje humano

N6 no lo calcula el sistema. Una persona revisa brecha, oportunidad y PDF, sin ver antes el resultado automático. Marca correcta (1), parcial (0.5) o incorrecta (0); las dos últimas exigen justificación. También declara si llegó al juicio por lectura directa o revisión asistida.

Estado	Puntaje	Requisito
Correcta	1.0	La brecha representa adecuadamente el artículo.
Parcial	0.5	Acierta el problema, pero falla en un matiz; requiere explicación.
Incorrecta	0.0	No representa correctamente el artículo; requiere explicación.

La ceguera se impone en el backend: acierto y desglose permanecen nulos hasta completar todas las brechas. Si se elimina un veredicto, vuelven a ocultarse. El modelo admite varias personas, pero el piloto vigente tiene un solo anotador y no permite calcular acuerdo entre jueces.

7.10 Evidencia piloto

Medida	Resultado registrado
Artículos	5 de ingeniería
N6	3 correctas, 2 parciales; acierto ponderado 0.80
N2.6	Detectó las 2 brechas parciales en los casos que originaron la métrica
N2.5	1 contradicción entre 39 afirmaciones
N4.2	Mediana 0.905; IQR 0.009
ROUGE	No aplicable por resumen en español y abstract en inglés

N2.6 reproduce los dos casos usados para diseñarla; todavía no demuestra generalización. El siguiente experimento válido debe usar artículos nuevos y mantener el prompt congelado.

8. Seguridad, propiedad y cuota

La seguridad se apoya en fallar cerrado: configuración obligatoria, consultas filtradas por dueño, backend no expuesto directamente y claves de almacenamiento validadas.

Control	Implementación
Contraseñas	bcrypt directo; mínimo 8 caracteres y máximo 72 bytes para evitar truncamiento silencioso.
Sesión	JWT HS256 con secreto mínimo de 32 caracteres; 8 horas por defecto y techo absoluto de 7 días.
Renovación	Renueva actividad sin convertir el token en permanente; conserva inicio de sesión.
Propiedad	El filtro usuario/proyecto vive dentro de las consultas.
Respuesta ajena	404 en vez de 403 para no confirmar que el identificador existe.
Registro	Cerrado por defecto; la primera cuenta se crea desde terminal.
CORS	Lista explícita; no admite comodín con credenciales.
PDF	Clave usuario/uuid.pdf validada; backend y trabajador comparten volumen.
Red	FastAPI solo se publica en 127.0.0.1; Internet entra por Caddy.
Contenedor	Backend y trabajador se ejecutan como usuario sin privilegios.

8.1 Cuota de Gemini

La cuota gratuita pertenece a la clave, no a cada usuario. El sistema registra intentos exitosos y fallidos, limita velocidad mediante ventana deslizante y puede aplicar un reparto diario por cuenta antes de encolar. Analizar consume aproximadamente una generación por artículo; verificar, otra; sintetizar, una adicional.

Abrir el registro a desconocidos sin una estrategia de cuota y facturación permitiría que una sola cuenta consuma la capacidad compartida. Por eso REGISTRO_ABIERTO permanece falso por decisión de producto.

8.2 Riesgos todavía declarados

- No hay revocación inmediata de JWT; la caducidad y el techo absoluto son la defensa actual.
- La subida comprueba extensión y Caddy limita a 64 MB, pero el router lee el archivo completo y no valida todavía la firma binaria del PDF.
- Los PDF y respaldos principales viven en la misma instancia; perderla puede afectar ambos.
- No hay recuperación de contraseña ni borrado completo de cuenta.
- Publicar para terceros exigiría términos, privacidad y tratamiento de PDF con derechos de autor.

9. Ejecución, despliegue y operación

La laptop sirve para editar y probar. El sitio público vive en Oracle Cloud y se actualiza únicamente después de subir el código y reconstruir las imágenes en el servidor.

9.1 Entornos

Entorno	Cómo se ejecuta	Uso
Manual local	MySQL, backend, trabajador y Vite en terminales separadas	Desarrollo detallado y recarga rápida
Docker local	<code>docker compose up --build</code>	Reproducir el conjunto en localhost:8080
Producción	Docker Compose en VM Ubuntu de Oracle	Servicio permanente con HTTPS

9.2 Actualización manual

En Windows PowerShell 5.1, los comandos se ejecutan por separado:

```
git add -A
git commit -m "mensaje descriptivo"
git push
```

Luego se abre SSH y, ya dentro del servidor Ubuntu con bash:

```
cd ~/capstone-matriz && git pull && docker compose up -d --build
```

--build es obligatorio para cambios del frontend: Vite compila App.jsx y las variables VITE_* dentro de la imagen. docker compose up -d sin reconstruir puede dejar publicada la versión anterior.

9.3 Caddy y red

- DOMINIO vacío: HTTP local; DOMINIO definido: Caddy obtiene y renueva Let's Encrypt.
- Puerto 80 permanece abierto para validación y redirección a HTTPS; 443 sirve la aplicación.
- `handle /api/*` elimina `/api` y reenvía a `backend:8000`.
- `try_files` devuelve `index.html` para rutas profundas de React.
- Assets con huella reciben caché larga; `index.html` se sirve sin caché.
- El tamaño máximo de petición pública es 64 MB.

9.4 Persistencia y respaldos

Volumen	Contenido	Pérdida si se elimina
<code>datos_mysql</code>	Base completa	Usuarios, proyectos, ejecuciones y métricas
<code>pdfs</code>	Documentos originales	Fuentes usadas para análisis y revisión
<code>caddy_datos</code>	Certificados	Caddy deberá solicitarlos de nuevo
<code>caddy_config</code>	Estado de Caddy	Configuración interna persistente

`respaldar.sh` ejecuta `mysqldump` con transacción consistente, comprime, rechaza archivos menores de 1 KB y rota copias de más de siete días. El cron crea primero la carpeta del registro. La restauración se prueba en una base temporal para no tocar producción.

El respaldo actual está en la misma VM. Debe copiarse cifrado a almacenamiento externo y probarse periódicamente para proteger frente a pérdida completa de la instancia.

10. Pruebas, integración continua y diagnóstico

El backend se verifica contra MySQL real en CI. El frontend todavía solo tiene lint y compilación; esta es una de las mejoras prioritarias.

Trabajo	Comprobación
MySQL	Servicio vacío MySQL 8 con healthcheck
Migraciones	alembic upgrade head desde cero
Consistencia	alembic check detecta modelos sin migración
Backend	pytest completo en GEMINI_MODE=mock
Frontend	npm ci, ESLint y npm run build
Cuota	La CI no llama a Gemini ni gasta generaciones

10.1 Qué protegen especialmente las pruebas

- Migraciones y coincidencia entre modelos y base.
- Aislamiento entre usuarios y respuesta 404 para recursos ajenos.
- Cola, reintentos, recuperación de items y cierre de runs.
- Diferencia entre cero y métrica no aplicable.
- ROUGE por idioma, densidad léxica y contadores explicativos.
- N2.5, N2.6 y descomposición de afirmaciones.
- Revisión ciega y ocultación desde el backend.
- Exportaciones vigentes frente a historia completa.

10.2 Diagnóstico operativo

Síntoma	Primera comprobación
Análisis en 0 %	Confirmar que el servicio trabajador está activo.
409 análisis en curso	Revisar run activo y logs; un trabajador reiniciado recupera items abandonados.
429	Distinguir límite por minuto de cuota diaria; la diaria no mejora reintentando.
Failed to fetch	Revisar /health, VITE_API_BASE, Caddy y CORS del entorno local.
Esquema atrasado	Ejecutar alembic upgrade head; no usar schema.sql.
Rutas profundas 404	Comprobar try_files en Caddy y que la imagen nueva fue construida.
Pruebas bd omitidas	Falta MySQL o MYSQL_URI; omitidas no significa aprobadas.

11. Mejoras pendientes y orden recomendado

No hay una funcionalidad esencial inconclusa. Lo pendiente mejora reproducibilidad, precisión metodológica, calidad de interfaz y resiliencia operativa.

Orden	Mejora	Esfuerzo	Razón
1	Unificar documentación vigente	Horas	Eliminar contradicciones históricas.
2	Versionar fórmula, prompts, modelos y RAG	1-2 días	Prerrequisito para cambiar significados sin mezclar historia.
3	N1.2 con denominador real	1 día	Medir secciones que el artículo realmente contiene.
4	Precisar N2.1 y N2.2	1-2 días	Alinear nombres y denominadores con lo que verifican.
5	IQR descriptivo	Menos de 1 día	Retirar el umbral universal 0.05 hasta calibrar.
6	Pruebas de frontend	2-4 días	Detectar regresiones de comportamiento visible.
7	Respaldo externo	1-2 días	Cubrir pérdida completa de Oracle.
8	N2.6 con artículos nuevos	Varios días	Medir generalización y matriz de confusión.
9	N6 multi-anotador y calibración	Semanas	Acuerdo humano y umbrales empíricos.
10	Escalabilidad vectorial condicionada	Semanas	Solo si pruebas de carga muestran necesidad.

11.1 Dependencias metodológicas

Versionar viene antes de cambiar N1.2 o N2.2. N2.6 debe probarse con datos nuevos antes de ajustarse. N3, N5 e IQR no pueden calibrarse honestamente hasta ampliar N6. La infraestructura de permisos multi-anotador puede esperar: una evaluación ciega externa y una importación controlada permiten reunir evidencia sin construir todavía una fase de colaboración completa.

11.2 Límites que deben declararse

- N2.6 fue desarrollada a partir de dos casos y todavía no tiene validación externa.
- N6 tiene cinco casos, un anotador y ningún acuerdo entre jueces.
- La ventana de verificación contiene fragmentos recuperados y vecinos, no el artículo completo.
- N1.2, N2.2 y el umbral universal de IQR necesitan corrección o neutralización.
- N3.2, N3.3, N5.3 y N5.5 necesitan calibración humana.
- No hay pruebas automatizadas del frontend.
- La búsqueda vectorial es por fuerza bruta y está diseñada para corpus pequeños.
- Respaldos y PDF principales viven en la misma instancia.
- La observabilidad depende de logs manuales; no hay alertas integrales.

12. Política de cambios y nuevas ediciones del PDF

Este documento es una fotografía. No debe editarse como si un cambio futuro ya estuviera implementado. Primero se modifica y verifica el programa; después se genera una nueva edición.

Tamaño	Ejemplos	Tratamiento documental
Menor	Texto, estilo, accesibilidad o corrección interna sin cambiar contratos.	Puede anotarse en la próxima revisión; regenerar si cambia el uso visible.
Mediano	Endpoint, flujo de pantalla, fórmula, prompt, exportación, variable, migración o estrategia de pruebas.	Avisar antes. Tras aprobación, implementar, verificar y publicar una edición 1.x nueva.
Grande	Nuevo servicio, permisos, proveedor IA, motor vectorial, arquitectura de datos o infraestructura.	Detenerse y acordar diseño. Después del despliegue validado, publicar edición 2.0 o superior.

12.1 Cambios que obligan a avisar

- Modificar el significado, fórmula, denominador, dirección o umbral de cualquier N#.
- Añadir o retirar tablas, columnas, migraciones o relaciones de propiedad.
- Cambiar autenticación, duración de sesión, cuota o exposición de puertos.
- Alterar el pipeline, prompts, modelos, embeddings, fragmentación o recuperación.
- Cambiar el formato o semántica de una exportación.
- Sustituir Caddy, MySQL, Docker Compose, Oracle o el almacenamiento de PDF.
- Abrir registro, incorporar colaboración o permitir acceso de terceros.

Regla operativa: informar al propietario del alcance y el riesgo; esperar confirmación para cambios medianos o grandes; actualizar el programa; ejecutar pruebas y despliegue; finalmente regenerar este PDF con nueva fecha, commit y lista de cambios.

13. Guía de incorporación para otro desarrollador

El objetivo de esta sección es reducir el riesgo de que una persona nueva arregle una parte sin conocer la razón metodológica de las demás.

13.1 Orden de lectura

Orden	Fuente	Motivo
1	docs/CONTEXTO.md, sección 0	Estado vigente, decisiones recientes y siguiente paso.
2	docs/Metricas.md	Significado oficial de las 23 métricas.
3	docker-compose.yml y .env.example	Servicios y configuración sin secretos.
4	backend/main.py y app/dependencias.py	Montaje de API, sesión y propiedad.
5	trabajador.py, services/cola.py y routers/runs.py	Procesamiento asíncrono.
6	embedding_service.py y verificacion.py	RAG y lógica metodológica.
7	models/ y migraciones/	Persistencia y evolución del esquema.
8	frontend/src/App.jsx y sesion.js	Flujo visible y consumo de API.
9	tests/ y .github/workflows/ci.yml	Contratos ya protegidos.

13.2 Arranque seguro

Ruta Docker recomendada para comprender el conjunto:

1. Copiar .env.example a .env y completar MYSQL_PASSWORD y JWT_SECRETO.
2. Ejecutar docker compose up --build.
3. Crear la primera cuenta con crear_cuenta.py dentro del backend.
4. Abrir <http://localhost:8080>.
5. Confirmar que backend, trabajador, MySQL y frontend están sanos.

Nunca ejecutar database/schema.sql sobre una base existente. Nunca versionar .env. Nunca probar cambios en modo real si la comprobación puede hacerse en mock.

13.3 Lista antes de aprobar un cambio

- ¿Cambia un contrato HTTP, una fórmula o el significado de un dato?
- ¿Necesita migración Alembic y prueba desde base vacía?
- ¿Preserva aislamiento por usuario y respuesta 404 para lo ajeno?
- ¿Distingue nulo, cero y no aplicable?
- ¿Conserva resultados históricos y su versión?
- ¿Aumenta llamadas o cuota de Gemini?
- ¿Afecta backend y trabajador o el volumen compartido?
- ¿Requiere reconstruir frontend o reiniciar servicios?
- ¿Tiene prueba automática y comprobación visual cuando corresponde?
- ¿Es mediano/grande y requiere avisar antes de implementarlo?

14. Fuentes del repositorio y glosario

14.1 Fuentes principales

Fuente	Uso en este documento
README.md	Instalación, uso, pruebas, cuentas y operación.
docs/CONTEXTO.md	Estado, arquitectura, historia técnica y límites.
docs/Metricas.md	Descripción vigente de las 23 métricas.
docs/Plan_Limites_y_Niveles_Medicion.md	Orden de mejoras y N0-N6.
docker-compose.yml	Servicios, volúmenes, dependencias y variables.
backend/app/services/metricas/catalogo.py	Fuente de verdad de nombres, escalas y dirección.
backend/app/utills/text_extractor.py	Diagnósticos N0 y reglas de ingesta.
backend/app/services/verificacion.py	Afirmaciones, N2.1, N2.2, N2.4-N2.6.
backend/app/services/metricas/niveles.py	N1, N3, N4 y versión de N3.4.
backend/app/services/metricas/sintesis.py	N5.2, N5.3 y N5.5.
backend/trabajador.py y services/cola.py	Cola, reintentos y cierre.
frontend/Caddyfile y Dockerfiles	Compilación, proxy, HTTPS y contenedores.
.github/workflows/ci.yml	Pruebas y migraciones en integración continua.

14.2 Glosario

Término	Definición
Brecha	Limitación o trabajo pendiente identificado a partir de un artículo.
Oportunidad	Posible línea de investigación derivada de la brecha.
RAG	Generación aumentada por recuperación: se seleccionan fuentes antes de generar.
Embedding	Vector que representa significado y permite comparar textos.
MMR	Selección que equilibra relevancia y diversidad.
Run	Ejecución de análisis de un proyecto.
Run item	Artículo concreto procesado dentro de una ejecución.
IQR	P75 menos P25; amplitud del 50 % central.
Evidencial	Afirmación factual que debe sustentarse en el artículo.
Inferencial	Conclusión derivada; no necesita aparecer literalmente.
Ceguera	Procedimiento que oculta resultados automáticos hasta completar el juicio humano.
Alembic	Sistema que versiona y aplica cambios de esquema.

Fin de la edición 1.0. Para una nueva edición, actualizar fecha, commit, migraciones, pruebas, arquitectura, catálogo N# y lista de cambios verificados.